Relatório de teste: carga com k6

SafeID · Commit f9677df da main · Executado em 03/11/2026 · Horários em UTC

> **Resultado: metas medidas atingidas.** Foram 204.487 requisições em 3 execuções, com 0,00% de erro, nenhum alarme disparado e nenhum 5xx. As metas de cache, Motor de Risco e fila da Tabela 2 **não puderam ser medidas** pelo motivo explicado abaixo.

Objetivo

Executar a campanha da Seção 5.5.3.2 do documento: aquecimento, patamar de 100 usuários virtuais por 5 minutos, pico de 300, recuperação, com 3 execuções e publicação da mediana e da amplitude dos P95.

Ambiente

- Alvo: produção, em us-east-2, com 1 task Fargate (0,5 vCPU e 1 GB), RDS db.t3.micro e ElastiCache cache.t3.micro. Produção roda a imagem anterior ao PR #123; a medição não é afetada, por bater em rotas não tocadas por ele.
- Gerador: k6 v2.3.0, em um único computador no Brasil. Script: `tests/load/k6-producao.js`.
- Execuções entre 18:01 e 18:37 UTC, com 1 minuto de intervalo. Cada usuário virtual faz 1 acesso por segundo: `GET /api/health` e, a cada 5 iterações, a página inicial.

Resultados da API (GET /api/health)

Fase	P95 (mediana)	P95 (amplitude)	Meta	Vazão	Erro máx.	Situação
Linha de base (20 VUs)	144 ms	144 a 150 ms	< 750 ms	20 req/s	0,00%	**Atingida**
Carga (até 100 VUs)	145 ms	144 a 151 ms	< 750 ms	90 req/s	0,00%	**Atingida**
Pico (300 VUs)	216 ms	206 a 217 ms	< 1.500 ms	233 req/s	0,00%	**Atingida**
Recuperação (20 VUs)	144 ms	144 a 150 ms	< 750 ms	20 req/s	0,00%	**Atingida**

Site no CloudFront

Fase	P95 (mediana)	P95 (amplitude)
Carga (até 100 VUs)	259 ms	258 a 259 ms
Pico (300 VUs)	257 ms	256 a 259 ms

Execuções

Execução	Requisições	Erro	Duração
1	68.151	0,00%	661 s
2	68.128	0,00%	661 s

Execução	Requisições	Erro	Duração
3	68.208	0,00%	661 s

Métricas da AWS no período

Métrica	Valor
ALB: requisições (soma)	170.407
ALB: tempo de resposta do alvo, máx. (s)	0,52
ALB: tempo de resposta do alvo, média (s)	0,005
ALB: erros 5xx do alvo (soma)	0
ALB: erros 5xx do ALB (soma)	0
Fargate: CPU, máx. (%)	73,105
Fargate: memória, máx. (%)	8,105
RDS: CPU, máx. (%)	7,15
RDS: conexões, máx.	10
RDS: créditos de CPU, mín.	288
Redis: CPU do motor, máx. (%)	1,35

O tempo médio de resposta do alvo no ALB foi de 5 ms, e a mediana vista pelo gerador ficou em torno de 140 ms. A maior parte da latência medida é a rede entre o Brasil e us-east-2.

Comparação com a Tabela 2 do documento

Cenário da Tabela 2	Meta	Situação
Pico de 300 usuários virtuais	P95 < 1,5 s; erro < 2%	**Atingida**
Consulta com acerto no cache Redis	P95 < 50 ms; ≥ 500 req/s	Não medida: não existe rota pública de consulta
Motor de Risco sem chamada externa	P95 < 100 ms; ≥ 250 req/s	Não medida: o motor não tem rota própria
API com fila BullMQ	P95 < 750 ms para enfileirar	Não medida: o enfileiramento só ocorre no cadastro e no monitoramento
Consulta nova à HIBP	Limitada pelo plano	Sem alteração: verificada no código; plano Core 1, 9 por minuto
Falha da fonte externa	Abrir com ≥ 50% de erro	Sem alteração: coberta por testes unitários

> **Recomendação:** reescrever a Tabela 2 com os cenários medidos, porque as rotas de cache, motor e fila deixaram de existir com a retirada da consulta manual. A meta de 100 VUs ≥ 500 req/s também não é alcançada com 1 acesso por segundo: a vazão real foi de cerca de 90 req/s na carga e 233 req/s no pico.

Pontos de atenção

- **CPU do Fargate chegou a 73%** no pico, com cerca de 233 req/s em uma rota simples. Há margem, mas pouca para rotas mais pesadas com 1 task e sem auto scaling.
- O RDS ficou folgado, com CPU máxima de 7%, e as conexões bateram no limite configurado de 10, sem erro.

Limitações

- `/api/health` faz só um SELECT 1 e um PING no Redis. Rotas com login, descriptografia e IA são mais pesadas e não foram medidas, porque as demais respondem 429 depois de 100 requisições a cada 15 minutos por IP.
- Todo o tráfego saiu de um único IP e de um único computador.
- Não houve teste de duração prolongada (soak) nem busca do ponto de ruptura.